

BILAN

Ecriture scoldire et universitaire: Carpus, Analyses Linguissiques, Man.

UE: Projet Professionnel

Master Sciences du Langage, parcours Industrie de la Langue GIROUD Océane
LIU Jingyu
NARTIN Célia

TABLE DES MATIÈRES

TABLE DES MATIERES	2
Présentation des parties A. Maîtres d'oeuvres i. Coordonnées ii. Description B. Maître d'ouvrage i. Coordonnées iii. Description	3 3 3 3 3 3 3
II. Présentation du projet	4
A. Présentation de e-calm	4
B. Réalisation du projet et public visé	4
III. Analyse de l'existant	5
A. Analyse de la demande	5
B. Bilan de l'existant	5
C. Résultat de la demande	6
IV. Spécificités fonctionnelles	6
A. Fonctionnalités essentielles	6
B. Fonctionnalités optionnelles	12
IV. Spécificités techniques	13
A. Langages et outils	13
B. Données	14
C. Hébergement	14
V. Planning : Respect des dates	14
VI. Scénarios réalisés	15
V. Conclusion	15

I. Présentation des parties

A. Maîtres d'oeuvres

1. Coordonnées

GIROUD Océane

06 03 99 81 92

oceane.giroud@etu.univ-grenoble-alpes.fr

LIU Jingyu

06 68 95 41 81

jingvu.liu@etu.univ-grenoble-alpes.fr

MARTIN Célia

06 35 21 75 33

celia.martin1@etu.univ-grenoble-alpes.fr

2. Description

Notre équipe est constituée de trois étudiantes en master 2 Sciences du Langage, parcours Industrie de la langue. Ce projet est réalisé dans le cadre du cours projet professionnel encadré par Monsieur Thomas Lebarbé.

B. Maître d'ouvrage

1. Coordonnées

PONTON Claude

0476824397

Claude.Ponton@univ-grenoble-alpes.fr

2. Description

- Maître de conférences à l'Université Stendhal Grenoble 3
- Chercheur au Laboratoire de Linguistique et Didactique des Langues Étrangères et Maternelles (LIDILEM)

II. Présentation du projet

A. Présentation de e-calm

Dans le cadre du projet ANR E:Calm (Écritures scolaires : Corpus, Analyses Linguistiques, Modélisations didactiques), les chercheurs s'intéressent à la description linguistique de copies d'élèves et d'étudiants allant du CP au Master. Ce projet a pour objectif la réalisation et la mise à disposition d'un corpus d'écrits d'élèves et d'étudiants, la description des performances des élèves et étudiants tout au long de leur scolarité et de voir les attentes des enseignants sur certaines compétences scripturales (orthographe et cohérence textuelle) dans des analyses sociologiquement contextualisées. Il vise aussi à étudier les modalités de l'écriture dans les avant-textes (plans, notes, brouillons) et les textes à travers les écrits remis par les élèves et les interventions sur les copies par les enseignants. Pour cela des outils d'analyse textuelle sont utilisés. Ce projet est financé pour 42 mois.

Ce projet interdisciplinaire est réalisé par une équipe de Sciences de l'Éducation : CIRCEFT-ESCOL (Paris) et trois équipes de Sciences du Langage : Clesthia (Paris), CLLE-ERSS (Toulouse), Lidilem (Grenoble). Il a donné lieu à la réalisation de quatre corpus: Ecriscol, Littéracie avancée, Scoledit et Resolco qui sont tous les quatre présents dans la base de données que nous avons réalisée pour le projet.

B. Réalisation du projet et public visé

Nous avons réalisé une base de données regroupant toutes les données d'analyse de copies d'élèves et un site Web qui facilite l'interrogation des données et le calcul de quelques tableaux statistiques. Il permet aux utilisateurs (chercheurs, enseignants ou simples curieux) de consulter les données d'élèves et au(x) gestionnaire(s) de mettre la base de données à jour (suppression et ajout de données) sur ce système qui est stand-alone et en ligne.

III. Analyse de l'existant

A. Analyse de la demande

Le site permet d'utiliser une base de données pour apporter un système de sélection et de classification adaptée aux corpus d'E-Calm à l'aide d'une base de données, avec des critères de sélection spécifiques au corpus et la manière dont les chercheurs utilisent ces données.

L'objectif était d'une part d'établir une base de données pour le stockage des données d'analyse de copies d'élèves, et d'autre part de créer un site pour fournir aux chercheurs du projet et aux personnes intéressées par les données de E-Calm le moyen d'interroger facilement ces données. Il y avait également un besoin de pouvoir gérer ces données depuis le site pour faciliter l'ajout et la suppression sans passer par un système de gestion de base de données.

B. Bilan de l'existant

Les chercheurs du projet travaillent sur des fichiers csv traités avec excel contenant l'ensemble des données du corpus. La navigation à travers ces différentes données et leur interrogation est donc coûteuse en temps et implique un certain niveau de connaissances des fonctionnalités d'excel. Le traitement des données est donc lourd et compliqué. Par conséquent, pour les personnes qui souhaitent consulter rapidement les informations de ces fichiers, un site Web pouvant répondre aux exigences est nécessaire.

	A	8	C	D	E	F	G	H	
1	IdTok	• IdProd •	Niv	SegNorm	- SegTrans	• PhonNorm	• PhonTrans	SyllabNorm	 Syllab
2	EC-CM2-2018-XX-D1-S1850-V1-1-1	1850	CM2	<sent></sent>	<sent></sent>	88	811	The second of	<sent< td=""></sent<>
3	EC-CM2-2018-XX-D1-51850-V1-2-2	1850	CM2	<titre></titre>	<titre></titre>	88	88		<titre< td=""></titre<>
4	EC-CM2-2018-XX-D1-\$1850-V1-3-3	1850	CM2	Le	te	lice	llee	Le	Le
5	EC-CM2-2018-XX-D1-51850-V1-4-4	1850	CM2	robot	robot	moobbau	rroobbau	ro-bot	ro-ba
6	EC-CM2-2018-XX-D1-S1850-V1-5-5	1850	CM2	H	н	aach	aach	н	H
7	EC-CM2-2018-XX-D1-51850-V1-6-6	1850	CM2			88	88		-
8	EC-CM2-2018-XX-D1-51850-V1-7-7	1850	CM2			AN .	88		
9	EC-CM2-2018-XX-D1-51850-V1-8-8	1850	CM2	<sent></sent>	<sent></sent>	20	89		<sent< td=""></sent<>
10	EC-CM2-2018-XX-D1-51850-V1-9-9	1850	CM2	Deuzio	Deuzio	ddeuzzyyau	ddeuzzyyau	Deu-zio	Deu-z
11	EC-CM2-2018-XX-D1-51850-V1-10-10	1850	CM2			88	88	E-100	
12	EC-CM2-2018-XX-D1-51850-V1-11-11	1850	CM2	11	II.	20	101	II.	15
13	EC-CM2-2018-XX-D1-51850-V1-12-12	1850	CM2	était	était	eittai	eittai	é-tait	é-tait
14	EC-CM2-2018-XX-D1-51850-V1-13-13	1850	CM2	une	une	uunn	uunn	u-ne	u-ne
15	EC-CM2-2018-XX-D1-51850-V1-14-14	1850	CM2	fois	fois	ffwwaa	ffwwaa	fois	fois
16	EC-CM2-2018-XX-D1-51850-V1-15-15	1850	CM2	un	un	un	un	un	un
17	EC-CM2-2018-XX-D1-51850-V1-16-16	1850	CM2	robot	robot	moobbau	rroobbau	ro-bot	ro-bo
18	EC-CM2-2018-XX-D1-51850-V1-17-17	1850	CM2	nommé	nommait	nnoommei	nnoommai	nom-mé	nom-
19	EC-CM2-2018-XX-D1-51850-V1-18-18	1850	CM2	H	н	aach	aach	н	H
20	EC-CM2-2018-XX-D1-51850-V1-19-19	1850	CM2	133	40	88	88		199

Figure 1 : Ensemble des données du corpus sur Excel.

C. Résultat de la demande

Nous avons créé une base de données pour stocker et classifier les données des fichiers csv. Nous avons également réalisé une plateforme en ligne permettant de consulter les données en sélectionnant les informations pertinentes pour l'analyse ainsi qu'en affichant les données statistiques sur le corpus.

Ce site permet d'exporter les résultats d'interrogation au format tsv et d'exporter un exemplier pour visionner les données.

Ce site possède également une partie gestionnaire donnant la possibilité à l'administrateur de modifier les données dans la base de données.

IV. Spécificités fonctionnelles

A. Fonctionnalités essentielles

1. Interrogation des données et résultats de la requête

Comme convenu, le site se découpe en deux parties distinctes : l'une permettant à l'utilisateur d'entrer les critères d'interrogation des données qu'il souhaite, l'autre affichant les résultats de la requête.

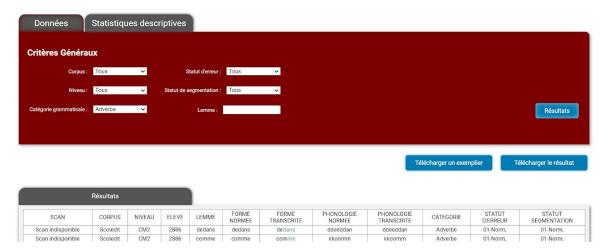


Figure 2 : Critères généraux, affichage des adverbes sur le site E-Calm.

a. Partie Interrogation des données :

La partie pour l'interrogation des données a été subdivisée en deux sous-parties matérialisées par des boutons : la première "Données" permet à l'utilisateur de trier les données qu'il souhaite afficher, la deuxième "Statistiques descriptives" permet de sélectionner un tableau de statistiques à calculer en fonction du contenu de la base de données.

i. La partie "Données":

Cette partie permet de sélectionner un nom de corpus, un niveau d'étude, une catégorie grammaticale, un statut d'erreur, un statut de segmentation et un lemme. Une fois ces données saisies et que l'utilisateur a appuyé sur le bouton "Résultats", les lignes ressorties par la requête à la base de données sont affichées dans la partie "Résultats".

Lorsque l'utilisateur sélectionne la catégorie de Verbe ou d'Adjectif, nous avons fait en sorte qu'il lui soit possible d'entrer des critères plus avancés : tiroir verbal, personne, type d'erreur et sélection d'une base / d'une désinence pour les verbes; genre, nombre, présence ou non d'une erreur de genre (et non type d'erreur de genre comme nous l'avions mis dans le cahier des charges à l'origine car nous n'avions pas cette information, nous n'avions accès qu'à la précision de l'existence d'une erreur ou non sur le genre), présence ou non d'une erreur sur le nombre (même modification que pour le genre) pour les adjectifs.

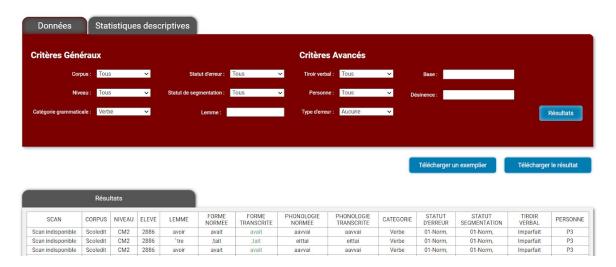


Figure 3 : Critères avancés, affichage des verbes ne contenant aucune erreur sur le site E-Calm.

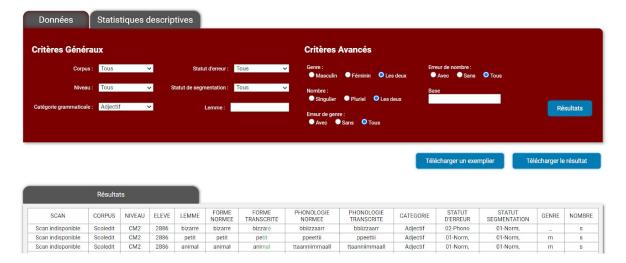


Figure 4 : Critères Avancés, affichage des adjectifs sur le site E-Calm.

ii. La partie Statistiques descriptives :

Nous avons fait en sorte que l'utilisateur puisse sélectionner le tableau à afficher dans un droplist. En fonction du tableau sélectionné, des critères peuvent être sélectionnés pour affiner le résultat des statistiques. Les tableaux suivants n'ont pas de critères particuliers:

- -Nombre de mots des productions
- -Répartition des POS en fonction du niveau
- -Répartition des tiroirs verbaux
- -Nombre de formes verbales analysées

Le tableau "Nombre de formes verbales, de bases et de désinences analysées" a été supprimé de la liste à la demande du commanditaire.

Le tableau "Répartition des formes verbales selon si leur base et/ou leur désinence sont normées" fait finalement partie des tableaux pour lesquels l'utilisateur peut sélectionner des critères (sélection d'un groupe de verbe et d'un tiroir verbal).

Il est possible de sélectionner un groupe verbal et/ou un tiroir verbal pour les tableaux suivants :

- -Proportion de bases et de désinences normées et non normées
- -Répartition des échecs et réussites pour les tiroirs verbaux les plus employés
- -Répartition des formes verbales non normées selon si leur base et/ou leur désinence respectent ou non la phonologie

Le tableau "Répartition des erreurs" a été supprimé de la liste car il ne faisait finalement pas partie des tableaux que nous pouvions afficher.

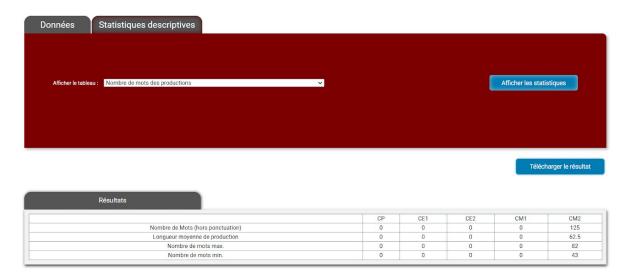


Figure 5 : Onglet statistiques descriptives, affichage des statistiques sur le nombre de mots des productions sur le site E-Calm.

b. Partie Résultats

i. Affichage des données

Les données affichées reprennent les colonnes du csv comme il a été précisé dans le cahier des charges. Lorsque la catégorie qui a été sélectionnée n'est pas un verbe ou un adjectif nous avons donc les colonnes : scan, corpus, niveau, élève, lemme, forme normée, forme transcrite, phonologie normée, phonologie transcrite, catégorie, statut d'erreur, statut de segmentation.

SCAN	CORPUS	NIVEAU	ELEVE	LEMME	FORME NORMEE	FORME TRANSCRITE	PHONOLOGIE NORMEE	PHONOLOGIE TRANSCRITE	CATEGORIE	STATUT D'ERREUR	STATUT SEGMENTATION
Scan indisponible	Scoledit	CM2	2886	dedans	dedans	dedans	ddeeddan	ddeeddan	Adverbe	01-Norm,	01-Norm,
Scan indisponible	Scoledit	CM2	2886	comme	comme	comme	kkoomm	kkoomm	Adverbe	01-Norm,	01-Norm,
Scan indisponible	Scoledit	CM2	2886	dedans	dedans	dedans	ddeeddan	ddeeddan	Adverbe	01-Norm,	01-Norm,

Figure 6 : Affichage des résultats sur le site E-Calm.

Lorsqu'un verbe est sélectionné deux colonnes s'ajoutent : tiroir verbal et personne.



Figure 7 : Affichage des verbes sur le site E-Calm.

Lorsqu'un adjectif ou un nom est sélectionné, deux colonnes s'ajoutent également : genre et nombre.

	s												
SCAN	CORPUS	NIVEAU	ELEVE	LEMME	FORME NORMEE	FORME TRANSCRITE	PHONOLOGIE NORMEE	PHONOLOGIE TRANSCRITE	CATEGORIE	STATUT D'ERREUR	STATUT SEGMENTATION	GENRE	NOMBRE
Scan indisponible	Scoledit	CM2	2886	pierre	pierres	pierres	ppyyairr	ppyyairr	Nom	01-Norm,	01-Norm,	f	р
Scan indisponible	Scoledit	CM2	2886	cou	cou	cou	kkou	kkou	Nom	01-Norm,	01-Norm,	m	S
Scan indisponible	Scoledit	CM2	2886	craie	craie	crai	kkrrai	kkrrai	Nom	02-Phono	01-Norm,	f	S
Scan indisponible	Scoledit	CM2	2886	bonjour	Bonjour	Bonjour	bbonjjourr	bbonjjourr	Nom	01-Norm,	01-Norm,	m	S
		0110									****		

Figure 8 : Affichage des noms sur le site E-Calm.

Dans la forme transcrite apparaît en rouge les parties fausses du mot, en vert les parties justes.

2. Page de connexion

Cette page est nécessaire pour les gestionnaires qui doivent se connecter sur ce site pour modifier les données (ajout et suppression). Nous avons ajouté un bouton permettant le retour sur la page principale. Effectivement, si l'utilisateur n'ayant pas de compte se trouve sur cette page, il lui suffit de cliquer sur le lien de "Retour à la page d'accueil".

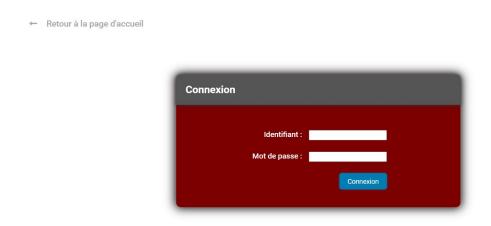


Figure 9 : Page de connexion pour le gestionnaire.

Nous n'avons pas conçu de page permettant la modification du mot de passe ou de création d'un nouveau compte car le commanditaire est le seul administrateur en charge du projet. En revanche, l'administrateur peut entrer directement dans la base de données pour ajouter ou supprimer des comptes gestionnaires via le compte phpMyAdmin dont il dispose.

3. Partie gestion:

Lorsque le gestionnaire a pu se connecter via la page de connexion, il a accès à un bouton supplémentaire "Ajout et Suppression des données". Cela lui permet d'ajouter un jeu de données ou d'en supprimer.

En ce qui concerne l'ajout, il faut impérativement que le fichier soit formaté de la même manière que le fichier csv que nous avions pour modèle et qui nous avait été délivré par le commanditaire : une ligne correspond à un mot décrit à l'aide de 33 colonnes (IdTok, IdProd, Niv, SegNorm, SegTrans, PhonNorm, PhonTrans, SyllabNorm, SyllabTrans, Categorie, Lemme, StatuErreurSimp, StatutErreur, StatutSegm, Genre, Nombre, BaseAdjNorm, GenreAdjNorm, NombreAdjNorm, BaseAdjTrans, GenreAdjTrans, NombreAdjTrans, ErreurAdjBase, ErreurAdjGenre, ErreurAdjNombre, VerPers, BaseVerForme, DesiVerForme, BaseVerProd, DesiVerProd, ErrVerBase, ErrVerDes, ErrVerBaseEtDes). Pour que l'exemplier fonctionne il vaut mieux avoir un découpage en phrase à savoir que les balises <sent> </sent> encadre les phrases dans le fichier.

Pour la suppression, le site permet de supprimer toutes les données correspondant à un niveau et un corpus sélectionnés par le gestionnaire. Seules ces actions sont possibles à la demande du commanditaire.



Figure 10 : Onglet Ajouter et supprimer des données sur le site E-Calm.

4. Déconnexion

Le bouton en haut à droite de la page permet au gestionnaire de se déconnecter une fois l'ajout ou la suppression effectuée. Il est alors redirigé vers la page d'accueil et ne peut plus ajouter ou supprimer des données.

B. Fonctionnalités optionnelles

1. Téléchargement des résultats

Lorsque l'utilisateur est sur la fenêtre "Données" ou "Statistiques descriptives" il lui est possible de télécharger le résultat de sa requête directement sur son ordinateur dans un fichier au format tsv.

2. Téléchargement d'un exemplier

Cette fonctionnalité n'est présente que sur la fenêtre "Données". Elle permet de choisir un mot et un nombre de lignes et de télécharger un fichier tsv contenant des exemples (du nombre de lignes sélectionné par l'utilisateur) de phrases contenant ce mot. Cette fonctionnalité peut contenir des erreurs car nous avons dû nous baser sur les balises <sent></sent> présentes dans le fichier csv d'exemple que nous avions du commanditaire. Il est donc possible qu'en l'absence de ces balises ou pour des raisons que nous pouvons difficilement anticiper, des erreurs ou des mots / balises non voulues apparaissent au téléchargement du fichier.

3. Page d'erreur

Il s'agit d'une petite fonctionnalité supplémentaire qui permet à l'utilisateur d'être envoyé sur une page du site lui donnant la possibilité de retourner à la page d'accueil lorsqu'une erreur est survenue et a pu être identifiée. Il lui suffit donc d'appuyer sur le bouton "Retour à la page d'accueil" au lieu de faire retour et d'avoir des problèmes avec l'envoi des formulaires.

Erreur 404 : page non trouvée.

Figure 11 : Page d'erreur du site E-Calm.

IV. Spécificités techniques

A. Langages et outils

Pour la réalisation de notre produit dans le cadre du projet ANR E-Calm, nous avons utilisé les langages, toolkits et applications suivants:

- PHP : pour le traitement des données et l'interaction avec la base de données (à l'aide de requêtes SQL).
- HTML : pour la structuration du site.
- CSS/JS : pour les aspects graphiques du site.
- JS (JQUERY) : pour l'interactivité du site.
- AJAX : communication asynchrone avec le serveur pour l'envoi des formulaires.
- MySQL : pour faire les requêtes pour interroger / gérer la base de données.
- PhpMyAdmin: système de gestion de base de données pour la création et la gestion de la base de données des corpus.

Nous avons utilisé l'architecture MVC (Model View Controller) pour réaliser ce projet. Cette méthode sépare les fichiers en trois modules (Modèle pour la partie traitement des données, Vue pour l'affichage dans le navigateur, Contrôleur pour lier le modèle et la vue) afin notamment de travailler en parallèle sur plusieurs fichiers et de faciliter notre organisation. De plus, elle facilite la lisibilité et il sera plus facile de reprendre le code si un développeur extérieur à notre groupe souhaite reprendre le projet.

Nous avons aussi usé de la programmation orientée objet afin également d'obtenir une meilleure organisation des fonctions, scripts et fichiers et faciliter notre programmation et celle des futurs développeurs qui reprendront le travail.

B. Données

Les données d'entrées pour l'ajout des données à la base de données doivent être au format csv. Un message d'erreur est retourné si le fichier n'est pas sous ce format, est vide ou s'il n'existe pas.

La base de données est composée de deux tables à la demande du commanditaire : la première recense les données du corpus : trente-trois colonnes ont été créées pour contenir les informations relatives à chaque mot. Nous n'avons pas créé de tables propres aux verbes et aux adjectifs également à la demande du commanditaire.

La seconde table est dédiée aux utilisateurs inscrits sur le site. Elle contient trois colonnes, la première pour l'id, la seconde pour l'identifiant et la dernière pour le mot de passe.

C. Hébergement

La plateforme en ligne est hébergée sur le serveur I3L de l'Université Grenoble Alpes. Notre produit est disponible via ce lien : http://i31.univ-grenoble-alpes.fr/~scoledit/projetpro_ecalm/index.php .

V. Planning: Respect des dates

Nous avons utilisé presque six semaines pour réaliser ce produit et nous avons réservé deux semaines pour revoir et améliorer tout le contenu de ce projet et terminer les fonctionnalités optionnelles qui ont causé des problèmes. Dans le processus de réalisation du produit, nous avons ajusté le temps de réalisation de chaque partie et le responsable en considérant la situation réelle. Toutefois, dans l'ensemble, le travail a été achevé comme prévu et les délais ont été respectés.

VI. Scénarios réalisés

Scénarios	Etat de réalisation
Connexion du gestionnaire.	Réalisé.
Modification des informations de la base de données (ajout et suppression).	Réalisé.
Sélection des critères généraux.	Réalisé.
Sélection des critères verbaux.	Réalisé.
Sélection des critères adjectivaux.	Réalisé.
Affichage des tableaux de statistiques.	Réalisé.
Exportation de l'exemplier au format tsv.	Réalisé.
Exportation du résultat d'interrogation.	Réalisé.
Déconnexion du gestionnaire.	Réalisé.

V. Conclusion

Dans le cadre du projet ANR E-Calm, le produit que nous proposons est une base de données et un site Web qui permet de consulter les données pour tous les utilisateurs et d'ajouter / de supprimer les données pour le gestionnaire. Les données sur lesquelles nous nous concentrons proviennent du résultat de l'analyse de copies des élèves allant du CP au Master. Il s'agit de donner aux utilisateurs qui s'intéressent à la description linguistique des données de ce projet, un moyen plus pratique d'accéder à de gros corpus de données.

Ce projet est créé dans l'optique de faciliter le travail des chercheurs et des enseignants qui pourraient consulter les erreurs récurrentes faites par des élèves sur un sujet, afficher les différents tableaux des statistiques des données et ainsi télécharger le résultat d'interrogation ou créer un exemplier à partir de la visualisation des copies.

Ce travail nous a permis de connaître les étapes de réalisation d'un produit, d'apprendre à interagir avec le commanditaire, à gérer un projet et à nous organiser pour le mener à bien. Il nous a permis à la fois d'affiner nos connaissances d'un point de vue informatique mais aussi d'un point de vue gestion de projet. La gestion du projet ayant été rendue difficile avec la crise sanitaire, cela nous a également appris à travailler à distance sur un projet long.